

DATATOUR 2026 — PHASE NATIONALE

Note méthodologique

Détection de fraude Mobile Money

Équipe Datawinners

Score public : 0,356478 · Score privé : 0,356984 (PR-AUC)

2ème place — Classement national final

4 juillet 2026

Sommaire

1. Résumé exécutif
2. Compréhension du problème
3. Description et exploration des données
4. Démarche méthodologique
5. Ingénierie des variables (feature engineering)
6. Modélisation
7. Validation et contrôle anti-fuite (leakage)
8. Résultats
9. Pistes explorées et écartées
10. Limites et recommandations
11. Reproductibilité

1. Résumé exécutif

Ce document présente la démarche complète, les hypothèses testées et les résultats obtenus par l'équipe Datawinners dans le cadre de la compétition DataTour 2026, dont l'objectif était de détecter les transactions frauduleuses au sein d'un jeu de données de transactions Mobile Money.

Le problème a été traité comme un exercice de classement (ranking) sous déséquilibre de classes, avec une contrainte temporelle forte : les données de test sont strictement postérieures aux données d'entraînement. Cette contrainte a orienté l'ensemble de la démarche méthodologique.

Résultat clé

Indicateur	Valeur
Score public (PR-AUC)	0,356478
Score privé (PR-AUC)	0,356984
Score de référence initial	0,349614
Gain obtenu (privé vs référence)	+0,00737 (+2,1 %)
Position au classement final (privé)	2 ^e / 32 équipes — écart au 1 ^{er} : 0,0000245

La progression a été obtenue exclusivement par accumulation d'idées de feature engineering validées individuellement — target encoding du risque par compte, pondération temporelle du risque, signatures comportementales — combinées via un blend de deux modèles LightGBM de complexités différentes, l'un d'eux utilisant une régularisation renforcée qui s'est révélée mieux généraliser sur l'ensemble complet du jeu de test.

Fait notable : la soumission retenue pour le score privé n'était pas celle affichant le meilleur score public au moment de la compétition — un signal a posteriori que la régularisation renforcée de ce modèle, bien que légèrement moins performante sur l'échantillon public (30 % du test), généralise mieux sur l'ensemble complet.

2. Compréhension du problème

2.1 Objectif

Prédire, pour chaque transaction du jeu de test, une probabilité de fraude. La métrique d'évaluation est la PR-AUC (Average Precision), particulièrement adaptée à un contexte de classes déséquilibrées où l'on cherche à bien classer les rares cas positifs plutôt qu'à maximiser une exactitude globale.

2.2 Contrainte temporelle

L'analyse préliminaire a révélé une séparation stricte entre les périodes d'entraînement (0 à 105) et de test (106 à 143), sans aucun chevauchement. Cette configuration impose une validation respectant l'ordre chronologique plutôt qu'un simple découpage aléatoire, et implique que le modèle doit généraliser vers un futur non observé.

2.3 Concentration du signal

Sur les cinq types d'opération présents dans le jeu de données, un seul (op_03, transfert de pair à pair) concentre 100 % des transactions frauduleuses observées, avec un taux de fraude de 31,2 %. Les quatre autres opérations affichent un taux de fraude nul sur l'ensemble de l'historique disponible. Cette observation a conduit à circonscrire la totalité de la modélisation à op_03, les autres opérations recevant un score de risque fixe et minimal en sortie.

3. Description et exploration des données

3.1 Volumétrie

Ensemble	Lignes	Colonnes
Entraînement	1 290 081	11
Test	430 100	10
Entraînement (op_03 uniquement)	415 323	11
Test (op_03 uniquement)	154 005	10

3.2 Colonnes disponibles

id, period, operation, amount, origin_account, origin_balance_before, origin_balance_after, destination_account, destination_balance_before, destination_balance_after, et fraud_flag (variable cible, présente uniquement dans l'entraînement).

Aucune variable contextuelle (appareil, localisation, identifiant réseau) n'est disponible — une limite structurelle discutée en section 10.

3.3 Observations comportementales clés

- 74,2 % à 80,3 % des comptes ayant émis au moins une transaction frauduleuse sont des comptes « mixtes », c'est-à-dire ayant également réalisé des transactions légitimes — cohérent avec un scénario de compromission de compte (usurpation de carte SIM) plutôt que de création de comptes dédiés à la fraude.
- Un test de validation croisée adversariale entre les distributions d'entraînement et de test donne une aire sous la courbe de 0,72, signalant une dérive significative du comportement entre les deux périodes.
- Les montants frauduleux sont en moyenne inférieurs aux montants habituels des comptes concernés, suggérant une stratégie de discrétion plutôt que d'extraction maximale en une transaction.

4. Démarche méthodologique

La démarche a suivi un cycle itératif discipliné, répété pour chaque nouvelle variable ou hypothèse :

- Formulation d'une hypothèse ancrée dans un raisonnement métier (comportement plausible d'un fraudeur ou d'une victime).

- Construction de la variable en validation croisée stratifiée à cinq blocs, sans jamais laisser une observation contribuer au calcul de sa propre valeur.
- Double mesure : score global hors échantillon (OOF) et score restreint à la zone temporelle la plus récente de l'entraînement (periods 84 à 105), utilisée comme proxy du comportement attendu sur le test.
- Contrôle de stabilité temporelle : comparaison du ratio fraude / non-fraude entre zone ancienne et zone récente, pour détecter toute variable dont le signal s'érode avec le temps.
- Décision fondée sur la mesure et non sur l'intuition seule, y compris lorsque cela impliquait d'abandonner une hypothèse a priori solide.
- Confirmation finale par soumission sur la plateforme, seule source de vérité incontestable.

5. Ingénierie des variables

5.1 Variables de base (19)

Transformations directes : logarithme des montants et soldes (pour corriger une asymétrie mesurée à 6,60 sur la variable amount brute), variations de solde avant/après, ratio montant sur solde destinataire, indicateurs binaires d'incohérence comptable (compte destinataire vide, solde figé, solde négatif), et mesures de degré du compte (nombre de destinataires uniques pour un compte émetteur, nombre d'émetteurs uniques pour un compte destinataire).

5.2 Encodage du risque par entité (Target Encoding)

Trois clés d'encodage ont été retenues, chacune calculée par validation croisée à cinq blocs avec lissage bayésien :

Variable	Clé	Paramètre de lissage	Corrélation
orig_te_m6	Compte émetteur	m = 6	0,2095
orig_te_hour_m6	Compte émetteur × heure du cycle	m = 6	0,0502
pair_te_m18	Paire émetteur → destinataire	m = 18	0,0556

5.3 Mémoire temporelle du risque

Deux implémentations ont été retenues pour pondérer davantage les observations récentes qu'anciennes dans le calcul du taux de risque par compte :

- Fenêtre glissante (orig_te_recent) : mélange à 70 % du taux calculé sur les trente dernières périodes du bloc d'entraînement et à 30 % du taux calculé sur l'historique complet.
- Pondération exponentielle continue (te_exp) : chaque transaction contribue au taux avec un poids $\exp(-\lambda \times \text{ancienneté})$, $\lambda = 0,05$, calibré empiriquement.

5.4 Signatures comportementales

Trois variables comparent chaque transaction à l'historique propre du compte émetteur : le rapport du montant au montant moyen historique, l'écart-réduit (z-score) du montant par rapport à la dispersion

historique, et le nombre de transactions déjà observées pour ce compte. Ces variables visent à détecter une rupture d'habitude, signature attendue d'une compromission de compte.

6. Modélisation

6.1 Choix de l'algorithme

LightGBM (Gradient Boosting sur arbres de décision) a été retenu comme algorithme principal, cohérent avec les pratiques documentées pour la donnée tabulaire déséquilibrée. XGBoost, CatBoost, Random Forest, Extra Trees, HistGradientBoosting, un réseau de neurones dense et une approche par forêt d'isolement (détection d'anomalies non supervisée) ont été testés à titre de comparaison ; aucun n'a dépassé la performance de LightGBM sur ce jeu de données précis.

6.2 Architecture finale retenue

Un blend pondéré de deux modèles LightGBM aux hyperparamètres volontairement différenciés :

Modèle	Feuilles	Taux d'apprentissage	Régularisation
LGB2	255	0,03	Standard (reg_alpha=0,5 ; reg_lambda=2,0)
LGB3	1 024	0,02	Renforcée (reg_alpha=2,0 ; reg_lambda=5,0 ; min_child_samples=50 ; feature_fraction=0,7 ; bagging_fraction=0,7)

La pondération du blend est proportionnelle au score de validation croisée (OOV) de chaque modèle, évitant tout réglage manuel arbitraire. La régularisation renforcée de LGB3 — testée initialement pour vérifier l'hypothèse qu'un modèle moins ajusté au train généraliserait mieux — a produit un score public très légèrement inférieur à notre meilleure configuration locale (0,356478 contre 0,356684), mais s'est révélée être la configuration ayant obtenu le meilleur score privé (0,356984), confirmant a posteriori cette hypothèse sur l'ensemble complet du jeu de test.

6.3 Gestion du déséquilibre de classes

Le paramètre `scale_pos_weight` est fixé au ratio du nombre de transactions légitimes sur le nombre de transactions frauduleuses (environ 2,21), corrigeant nativement le déséquilibre sans recours à un sur-échantillonnage synthétique (SMOTE), qui a été testé et s'est révélé légèrement contre-productif dans ce contexte précis.

7. Validation et contrôle anti-fuite

La fuite de données (data leakage) constitue le risque méthodologique le plus critique de ce projet, dans la mesure où plusieurs variables clés sont dérivées directement de la variable cible. Trois garde-fous ont été systématiquement appliqués :

7.1 Validation croisée stricte

Toute variable dérivée du taux de fraude est calculée exclusivement sur les blocs d'entraînement autres que celui auquel elle est appliquée. Un essai initial sans cette précaution a produit un score hors échantillon de 0,96 — un résultat statistiquement invraisemblable ayant confirmé la fuite avant tout usage en soumission.

7.2 Contrôle de granularité

Des encodages sur des clés trop fines (compte × heure avec pondération exponentielle, paire × heure) ont produit des scores locaux artificiellement élevés, immédiatement suivis d'une chute du score public réel (perte de 0,003 point observée sur un cas testé). Le diagnostic retenu est celui d'une fuite indirecte : un nombre insuffisant d'observations par groupe rend le lissage bayésien inefficace à compenser la sur-adaptation.

7.3 Confirmation par soumission réelle

Aucune amélioration mesurée localement n'a été considérée acquise avant confirmation par une soumission sur la plateforme. Plusieurs configurations affichant un score local supérieur (zone temporelle récente) ont in fine produit un score public inférieur à la configuration retenue — signe que ce proxy local perd en fiabilité pour des gains inférieurs à 0,001 point.

8. Résultats

8.1 Progression du score

Étape	Score public
Référence (19 variables de base)	0,349614
+ Target Encoding (compte / heure / paire)	0,353133
+ Signatures comportementales	0,353343
+ Mémoire temporelle (fenêtre 70/30)	0,355446
+ Blend LGB2 + LGB3, complexité optimisée	0,356104
+ Pondération exponentielle du risque ($\lambda = 0,05$)	0,356684
+ Régularisation renforcée de LGB3 (retenue en finale)	0,356478

8.1bis Score privé et soumission retenue

Indicateur	Valeur
Score public de la soumission retenue	0,356478
Score privé (classement officiel final)	0,356984
Position finale	2° / 32 équipes actives
Écart avec la 1 ^{re} place	0,0000245

Il est notable que la soumission retenue pour le classement final n'était pas celle affichant le meilleur score public au moment de la compétition (0,356684), mais une variante à régularisation renforcée légèrement moins performante en public (0,356478). Cet écart de +0,000506 point en faveur du score privé pour la configuration régularisée constitue une confirmation empirique, a posteriori, qu'une régularisation plus forte améliore la généralisation sur l'ensemble complet du jeu de test, même lorsque le proxy public local suggère l'inverse.

8.2 Importance des variables (modèle LGB3)

La décomposition du gain d'information (importance native de LightGBM) confirme la hiérarchie attendue : le taux de fraude historique du compte émetteur (13,3 % du gain total), l'écart du montant à la moyenne historique du compte (10,5 %), la mémoire temporelle courte (6,6 %), l'écart-réduit du montant (6,1 %) et la pondération exponentielle (6,0 %) concentrent à eux seuls près de la moitié du pouvoir prédictif du modèle sur vingt-sept variables.

9. Pistes explorées et écartées

Dans un souci de transparence méthodologique, le tableau suivant recense les principales pistes testées n'ayant pas été retenues, avec le diagnostic associé.

Piste testée	Diagnostic
Réseaux de neurones denses	Performance inférieure à LightGBM sur ce volume et cette dimensionnalité de données tabulaires.
Réseaux de neurones sur graphe (GNN)	Fuite structurelle liée à la propagation de messages sur un graphe englobant train et test.
Forêt d'isolement (détection d'anomalies)	Signal redondant avec les variables déjà capturées par les arbres de décision.
Sur-échantillonnage synthétique (SMOTE)	Dégradation légère de la performance ; le paramètre <code>scale_pos_weight</code> s'est révélé suffisant.
Augmentation de la complexité au-delà de 1 536 feuilles	Plateau, puis dégradation du score public malgré une amélioration du score local.
Encodage de paire avec pondération exponentielle	Corrélation isolée trop faible (0,0112) pour un nombre d'observations par paire insuffisant.

10. Limites et recommandations

10.1 Limites assumées

- Absence de données contextuelles (appareil, localisation) qui constitueraient vraisemblablement le levier de progression le plus significatif pour un système de production.
- Une fraction résiduelle des transactions frauduleuses (environ 1,3 % dans nos analyses d'erreur) ne se distingue statistiquement pas d'une transaction légitime dans l'espace de variables disponible — ces cas nécessiteraient une donnée comportementale en temps réel non présente ici.

- Le proxy de validation local perd en fiabilité en deçà de 0,001 point de gain, imposant une vérification systématique par soumission réelle pour tout arbitrage fin.

10.2 Recommandations pour une mise en production

- Réentraînement périodique du modèle : le risque associé à un compte à une mémoire courte, un modèle figé se dégraderait rapidement.
- Enrichissement prioritaire des données par des signaux contextuels (empreinte d'appareil, cohérence de localisation).
- Mise en place d'un circuit de contestation rapide pour l'utilisateur, tout système de score probabiliste produisant nécessairement des faux positifs.
- Exigence contractuelle de validation croisée documentée et de contrôle anti-fuite pour tout prestataire de scoring, un score de laboratoire n'étant pas une garantie de performance en production.

11. Reproductibilité

L'ensemble du pipeline est reproductible à partir des fichiers train.csv et test.csv fournis par l'organisateur. Le code complet, commenté, est fourni séparément (pipeline_complet.py). Les étapes s'exécutent séquentiellement :

```
1. Chargement et filtrage sur operation == "op_03"
2. Construction des 19 variables de base
3. Calcul des Target Encodings (compte, heure, paire) par validation croisée
4. Calcul des signatures comportementales
5. Calcul de la mémoire temporelle (fenêtre 70/30 et pondération exponentielle)
6. Entraînement des deux modèles LightGBM (5 blocs de validation croisée chacun)
7. Blend pondéré par score de validation croisée
8. Génération du fichier de soumission
```

Graine aléatoire fixée à 42 pour l'ensemble des opérations stochastiques (découpage en blocs, initialisation des modèles), garantissant une reproductibilité exacte du score annoncé de 0,356684.

Journal complet des quarante expérimentations menées — scores, hyperparamètres, notes justificatives — disponible dans journal_soumissions.csv, généré automatiquement par le module de suivi utilisé tout au long du projet.